Proyecto Integrador–Primera Entrega:

Tema: Ordinal Logistics Regression For Household Socioeconomic Status, Tepi Town (2022)

Sara Gabriela Chisaba Cárdenas

Juana Sofía Gómez Sánchez

Juan Esteban Silva Arévalo

Universidad Externado de Colombia

Machine Learning I

Docente: Juliana De Mier Medellin

21 de agosto del 2026

1. Comprensión y sustentación del artículo:

El artículo busca identificar qué factores están asociados al nivel socioeconómico de los hogares de Tepi Town, Etiopía. El nivel socioeconómico se divide en tres categorías ordenadas: bajo, medio y alto por otro lado para el estudio se analizaron 382 hogares de Tepi Town.

Los autores utilizaron regresión logística ordinal, ya que la variable que quieren explicar tiene categorías que siguen un orden, en particular, compararon dos modelos: el Proportional Odds Model (POM) y el Partial Proportional Odds Model (PPOM). El supuesto principal del POM es que el efecto de las variables explicativas se mantiene de forma proporcional entre los diferentes niveles de la variable socioeconómica. Cuando este supuesto no se cumple para alguna variable, el PPOM permite que su efecto cambie entre los niveles. Los autores compararon ambos modelos mediante el AIC y la prueba de razón de verosimilitud, y seleccionaron el PPOM porque presentó un mejor ajuste.

Los resultados del modelo final mostraron que la edad, el nivel educativo, el tamaño de la familia y el hábito de ahorro estaban significativamente asociados con el nivel socioeconómico. Por ejemplo, los hogares cuyo jefe tenía educación secundaria o superior y aquellos que tenían hábito de ahorro presentaban mayores probabilidades de pertenecer a un nivel socioeconómico alto. En cambio, un mayor tamaño familiar se relaciona con menores probabilidades de estar en un nivel socioeconómico alto.

Entre las principales limitaciones, los autores señalan que los datos fueron obtenidos mediante cuestionarios, por lo que podrían no recoger todos los aspectos relacionados con la situación socioeconómica de los hogares. Además, algunas variables, como los factores culturales, no fueron incluidas y podrían influir en el nivel socioeconómico.

2. Planteamiento del Problema

2.1. Pregunta problema: ¿Es posible clasificar y predecir con precisión el estatus socioeconómico de un hogar (SES) en función de sus características socioeconómicas y demográficas mediante un modelo de aprendizaje supervisado?

2.2. Tipo de Tarea:

Es un problema de clasificación ordinal al contar con etiquetas tanto en la base de datos como en la realidad, además se trata de variables categóricas que poseen una jerarquía como lo es el estatus socioeconómico.

2.3.Variable objetivo:

En este problema el target es el Nivel Socioeconómico del Hogar, este se divide en tres subgrupos; bajo, medio y alto. Dependiendo la rúbrica con la que se calcule y el conjunto de características que se considere, sin llegar a ruido o a insuficiencia explicativa en la información, los intervalos pueden variar un poco. En el paper guía, se emplea la escala Kuppuswamy modificada al año 2019. En general esta variable objetivo se obtiene del análisis de variables como nivel de educación, ocupación, ingresos, tamaño de la familia, hábito de ahorro y dependiendo del contexto social variables como religión y estado civil influyen en gran manera.

2.4.Relevancia del problema en el contexto colombiano y Latinoamericano:

El análisis de casos relacionados al estatus socioeconómico no solo repercute en la obtención de resultados sino en el planteamiento de soluciones óptimas y que beneficien a la población que lo necesite. Hablar de nivel socioeconómico no se reduce únicamente a un puntaje o a una categoría, es la combinación de un estilo y calidad de vida incluso proyecciones a futuro; más allá de una posición social se trata de educación y efectos en el desarrollo cognitivo, emocional, físico y de lenguaje de los individuos, afectando más en las primeras etapas de vida.

Conocer los factores que influyen en la clasificación de estratos socioeconómicos ayudará a clasificar los perfiles que necesitan el apoyo y las oportunidades que su contexto actual no le permite obtener y así mismo planear, aprobar e implementar planes de acción que tengan como fin principal mejorar la economía de los hogares y por consiguiente de la sociedad.

Según el Banco Mundial, para el año 2024 el índice de Gini fue de 54.6 llevando a Colombia a ser uno de los países con mayor desigualdad en el mundo. La situación no varía mucho en toda América Latina, donde el promedio regional es de 49.9 puntos, con países como Brasil, Panamá y Honduras con puntajes arriba de 45 y siendo el menor el de República Dominicana con 37 puntos. En comparación con otras regiones del mundo, son índices demasiado altos ya que, en países nórdicos, algunos asiáticos y europeos, los valores se mantienen inferiores o cercanos a 25 puntos.

Esto quiere decir que la mayoría de las riquezas se concentran en la minoría de personas, por lo que establecer modelos que ayuden a identificar a aquellos pertenecientes a clases bajas puede ser base para planteamiento de políticas públicas y herramientas que focalicen las ayudas estatales. Así mismo apoya en el reconocimiento de las áreas que necesitan fortalecimiento en orden de lograr un progreso económico.

2.5.Objetivos del paper a replicar:

- Identificar los factores determinantes que condicionan el estatus socioeconómico del hogar.
- Evaluar el rendimiento predictivo del modelo al clasificar los hogares en las distintas categorías socioeconómicas.

2.6.Técnicas del Curso:

El curso ofrece amplios conocimientos aplicables en cuanto a modelos principales; procesamiento de datos; evaluación, validación y ajuste de modelos y comunicación e interpretación. En este proyecto, alineado con la guía del paper, se utilizará el modelo de Regresión Logística Ordinal, se cuenta con un conocimiento a priori relacionado a ingeniería de características y balanceo de clases. En complemento a esto, se desarrollan habilidades de interpretación de hiper parámetros, métricas y resultados que permitan una traducción confiable y profesional que a su vez derive en propuestas de soluciones al problema planteado.

3. Estrategia de datos:

En el desarrollo del Proyecto integrador se utilizará la base de datos proveniente de la Gran Encuesta Integrada a Hogares, la cual es el resultado de un marco estructural del Sistema de Encuestas Sociales que busca caracterizar a la población colombiana con módulos destinados a conocer la calidad de vida de esta. Se emplearán específicamente los registros de diciembre de 2025, son datos reales y actuales que permitirán comprender el contexto socioeconómico del país.

A pesar de no tener una variable objetivo explícita, hay tres mecanismos a considerar que ayudan a clasificar el dataset en clase baja, media y alta, estos son: analizar el Ingreso Per Capita del Hogar expresado en Líneas de pobreza y clasificarlo

así: clase baja - <1.5LP; clase media - entre 1.5LP y 5 LP y clase alta ->5LP. Usar los estratos socioeconómicos ya establecidos y hacer la división categórica agrupando de a dos estratos en orden ascendente y finalmente, con el Índice de Riqueza.

Todos los métodos mencionados tienen ciertas limitaciones de aplicación y de interpretación, por ejemplo, el estrato en Colombia es una medida de la infraestructura urbana de la vivienda y podría no representar fielmente los ingresos del hogar, si bien es crucial para un análisis netamente social, no cubre con suficiencia el ámbito económico.

Por otro lado, se cuenta con variables relacionadas a la educación, a la ocupación, a los ingresos, al tamaño de familia y algunas culturales como el sexo y el estado civil. Dichas variables funcionarán como predictoras del nivel socioeconómico. La información completa se divide en 8 módulos cada uno con más de 50.000 filas y entre 40 y 100 variables, sin embargo, para efectos del proyecto se trabajará con una muestra representativa y con las variables de interés. Además, en cuanto a calidad hay algunas variables como Estrato, educación e ingresos presentan valores faltantes o de respuesta "No Sabe/No Responde" y al tratarse de variables categóricas hay respuestas que será necesario normalizar el texto.

4. Plan de Modelamiento y Base:

Para predecir el estatus socioeconómico (Bajo, Medio, Alto) de los hogares en Tepi, Etiopía, se plantea como enfoque principal la Regresión Logística Ordinal, específicamente el Modelo de Probabilidades Proporcionales Parciales (PPOM). Este método es el más idóneo para el problema, ya que respeta la jerarquía implícita de la variable ordinal y corrige la posible violación del supuesto de proporcionalidad en los datos.

Se consideran como modelos de referencia supervisados para evaluar el desempeño k-Nearest Neighbors (k-NN) y Random Forest Ordinal (o Naïve Bayes), evaluando su capacidad predictiva frente al enfoque ordinal estructurado.

Como referencia del paper propuesto se va a definir un modelo de línea base de clase mayoritaria. El cual evaluará la distribución de la muestra entre las distintas categorías socioeconómicas y predecirá sistemáticamente la clase con mayor frecuencia. De este modo, la proporción del grupo dominante establecerá el umbral mínimo de exactitud (Accuracy) que cualquier modelo propuesto deberá superar.

La evaluación de los modelos se guiará por el F1-Score Macro como métrica principal. Esta elección se justifica en el desbalance de las categorías y del contexto socioeconómico: clasificar por error a un hogar vulnerable (SES Bajo) en la categoría Alta le privará de subsidios y asistencia estatal crítica, mientras que clasificar a un hogar de clase Alta como Bajo derivaría en un uso ineficiente del gasto público. El F1-Score Macro garantiza penalizar por igual las equivocaciones en las tres clases sin verse distorsionado por la abundancia del grupo bajo.

Por último, la estrategia de validación prevista es una Validación Cruzada Estratificada de 5 pliegues. Este esquema asegura que cada subconjunto de prueba conserve la proporción real de las tres categorías garantizando evaluaciones confiables y sin sesgos.

5. Referencias:

- Banco Mundial. (2026). *Índice de Gini - Colombia* [Conjunto de datos]. Indicadores del Desarrollo Mundial. https://datos.bancomundial.org/indicador/SI.POV.GINI?locations=COLeli sho, M. E., Wogi, A. A., y Tareke, S. A. (2022). Ordinal Logistic
- Regression Analysis in Determining Factors Associated with Socioeconomic Status of Household in Tepi Town, Southwest Ethiopia. *The Scientific World Journal*, *2022*, Artículo 2415692. https://doi.org/10.1155/2022/2415692
- Das, S., y Rahman, R. M. (2011). Application of ordinal logistic regression analysis in determining risk factors of child malnutrition in Bangladesh. *Nutrition Journal, 10*, Artículo 124. https://doi.org/10.1186/1475-2891-10-124